

# Исследование и разработка методов планирования последовательностей интенций поверх Forward-Backward представлений в задачах сложной навигации

Автор: Савватей Степанов | Тема: Zero-Shot RL & Multi-Subgoal Planning

## 1 Введение и идея Forward-Backward представлений

В задачах обучения с подкреплением без предварительной специализации (Zero-Shot RL) центральным вопросом является способность агента решать новые задачи в известной среде без дополнительного сбора онлайн-опыта. Одним из наиболее элегантных подходов к этой проблеме являются Forward-Backward (FB) представления [2, 1].

### 1.1 Суть FB-представлений

Классический RL оптимизирует политику под конкретную функцию награды  $r(s, a)$ . В отличие от этого, FB-представления обучаются по оффлайн-датасету моделировать саму геометрию пространства переходов и структуру будущих посещений среды через низкоранговую факторизацию меры преемника (Successor Measure  $M(s, s')$ ):

$$M^{\pi_z}(s, s') = \mathbb{E}_{\pi_z} \left[ \sum_{t=0}^{\infty} \gamma^t \mathbb{I}(s_t = s') \mid s_0 = s \right] \approx F(s, z)^\top B(s'), \quad (1.1)$$

где  $F(s, z) \in \mathbb{R}^d$  — прямое (Forward) представление, кодирующее ожидаемые будущие состояния при следовании латентной интенции  $z \in \mathbb{S}^{d-1}$ , а  $B(s') \in \mathbb{R}^d$  — обратное (Backward) представление целевого состояния  $s'$ .

Величина скалярного произведения  $F(s, z)^\top B(g)$  имеет строгий физический смысл: она пропорциональна дисконтированной вероятности достижения окрестности цели  $g$  из текущей позиции  $s$  при исполнении намерения  $z$ . Соответственно, при появлении новой целевой задачи  $g$  оптимальная интенция в латентном пространстве находится как:

$$z^* = \arg \max_{z \in \mathbb{S}^{d-1}} F(s, z)^\top B(g). \quad (1.2)$$

### 1.2 Иерархическая структура и проблема Single-Intention бейзлайна

В базовой иерархической схеме [1] система разделена на два уровня:

1. **Low-level политика**  $\pi^\ell(a \mid s, z)$  — обученный контроллер, преобразующий латентную интенцию  $z$  и текущее состояние робота  $s$  в управляющие крутящие моменты моторов суставов  $a \in [-1, 1]^8$ .
2. **High-level контроллер**  $\pi^h(s, B(g)) \rightarrow z$  (в коде — `high_actor`) — модель, выбирающая единую глобальную интенцию на всю задачу целиком.




Рис. 1.1: Сравнение механизмов управления: базовый Single-Intention контроллер (слева), пытающийся идти сквозь препятствия, и последовательное планирование траектории подцелей (справа).

На практике в сложных невыпуклых лабиринтах (AntMaze) такой одношаговый подход неизбежно терпит неудачу. Муравей (Ant) — это сложная нелинейная динамическая система с 8 суставами, моментами инерции и контактным трением. Получая команду идти напрямую к цели  $g$ , находящейся за U-образным тупиком или толстой стеной, вектор  $z_g$  направляет усилия робота прямо в стену (эффект «мухи на стекле»). Робот упирается в угол, теряет кинематический баланс, переворачивается и застревает.

Для преодоления этого фундаментального ограничения необходимо перейти от выбора единичной интенции к **рассуждению о последовательности промежуточных подцелей (Multi-Subgoal Planning)**, не прибегая при этом к тяжелым генеративным диффузионным моделям мира.

## 2 Первая идея: Рекурсивное деление (Recursive Bisection)

### 2.1 Мотивация и идея метода

Моей первой идеей при переходе от одного шага к последовательности подцелей было построить иерархическое деление пути пополам (Bisection Planning). Логика казалась предельно простой и интуитивной: если агент не может дойти до далекой цели  $g$  за один шаг, давайте найдем в оффлайн-датасете такое промежуточное состояние  $w^*$ , которое максимально достижимо из текущего положения  $s$ , и из которого сама цель  $g$  также максимально достижима.

Формально промежуточная точка выбирается из пула  $N_{\text{cand}}$  случайных ориентиров датасета путем максимизации логарифмической суммы достижимостей:

$$w^* = \arg \max_{w \in \mathcal{D}_{\text{cand}}} \left[ \log (F(s, B(w))^{\top} B(w)) + \log (F(w, B(g))^{\top} B(g)) \right]. \quad (2.1)$$

После нахождения точки  $w^*$  процедура рекурсивно применяется к отрезкам  $(s, w^*)$  и  $(w^*, g)$  до достижения заданной глубины  $D$  (на практике  $D = 2$  или  $3$ ). В результате формируется цепочка подцелей  $[w_1, w_2, \dots, g]$ , которая затем последовательно передается в  $\pi^h$  или  $\pi^{\ell}$ .

---

**Алгоритм 1:** Рекурсивное бисекционное планирование в FB-пространстве

---

**Вход:** Текущее состояние  $s$ , вектор цели  $B(g)$ , глубина  $D$ , порог  $\tau_{hit}$

**Выход:** Последовательность промежуточных точек  $\mathcal{P}$

```
1 Функция Bisect( $s_a, s_b, d$ ):  
2   if  $d = 0$  или  $F(s_a, B(s_b))^T B(s_b) > \tau_{hit}$  then  
3     return  $[s_b]$ ;  
4   end  
5    $w^* \leftarrow \arg \max_{w \in \mathcal{D}_{cand}} [\log(F(s_a, B(w))^T B(w)) + \log(F(w, B(s_b))^T B(s_b))]$ ;  
6   return Bisect( $s_a, w^*, d - 1$ ) + Bisect( $w^*, s_b, d - 1$ );  
7  $\mathcal{P} \leftarrow$  Bisect( $s, g, D$ );
```

---

## 2.2 Почему метод не сработал: анализ проблем

Реализовать этот алгоритм было очень легко, поэтому я сразу закодил его и проверил на бенчмарке. Однако результаты оказались разочаровывающими: на лабиринте Medium успешность практически не превысила бейзлайн ( $\approx 74 - 76\%$ ), а на лабиринте Large упала еще сильнее.




Рис. 2.1: Типичная ошибка рекурсивного деления: в U-образном тупике точка  $w^*$  выбирается внутри тупика, так как прямое евклидово расстояние обманывает скалярное произведение FB-функции.

При детальном анализе траекторий вскрылись две ключевые проблемы:

1. **Отсутствие локального учета топологии стен:** Скалярное произведение  $F(s, B(w))^T B(w)$  в непрерывных нейросетевых представлениях имеет гладкое пространственное «просачивание» (diffusion leak) сквозь стены. В результате оптимизация (2.1) часто выбирает точку  $w^*$ , находящуюся прямо в середине тупика (рис. 2.1), усугубляя застревание.
2. **Накопление ошибок (Error Compounding):** При  $D = 3$  формируется 8 подотрезков. Если хотя бы на одном из них робот отклоняется от курса, все последующие цели становятся недостижимыми без полного глобального пересчета.

### 3 Вторая идея: Графовое планирование (Search on the Buffer)

#### 3.1 Построение топологического графа достижимости

После неудачи с наивным делением пополам стало очевидно: среда представляет собой сложный топологический лабиринт с жесткими стенами, и кратчайший путь должен искаться глобально с гарантией проходимости. В литературе по офлайн-RL для этого используется парадигма Search on the Buffer [5, 6].

Я реализовал построение ориентированного графа  $G = (V, E)$  поверх оффлайн-датасета:

1. **Ориентиры (Landmarks):** Сэмплируется  $N$  репрезентативных состояний  $\{s_1, \dots, s_N\}$  из оффлайн-буфера ( $N = 1000$  для Medium,  $N = 2000$  для Large).
2. **Матрица достижимости:** Для всех пар ориентиров вычисляется направленная мера  $R_{ij} = F(s_i, B(s_j))^T B(s_j)$ .
3. **Квази-метрическая стоимость ребра:**

$$c(s_i, s_j) = -\log \left( \frac{\max(R_{ij}, 10^{-6})}{\max_k R_{kk}} \right). \quad (3.1)$$

4. **Двухуровневая фильтрация ложных переходов:** Чтобы исключить «просачивание сквозь стены», ребра фильтруются:
  - По евклидову радиусу:  $c(s_i, s_j) = \infty$ , если  $\|s_i[:2] - s_j[:2]\| > R_{\text{edge}}$  ( $R_{\text{edge}} = 3.5$  м).
  - По порогу FB-достижимости:  $c(s_i, s_j) = \infty$ , если  $R_{ij} < \tau_{\text{cutoff}}$  ( $\tau_{\text{cutoff}} = 35.0$ ).

По полученной разреженной матрице стоимости один раз при старте задачи запускается алгоритм Дейкстры, возвращающий оптимальный дискретный маршрут  $\mathcal{P} = [s_{\text{start}}, v_1, v_2, \dots, v_K, g]$ .

#### 3.2 Механизм скользящего окна упреждения (Sliding Lookahead)

Первые запуски показали важную физическую особенность: если просто переключать целевой вейпоинт дискретно (по достижению радиуса 1.0 м), 8-суставный муравей резко тормозит, теряет кинематический импульс и вписывается в углы по ломаной траектории.




Рис. 3.1: Схема графового планировщика: фильтрация ложных связей сквозь стены и непрерывное ведение агента вдоль топологической траектории с упреждением  $L_{\text{lookahead}} = 2.6$  м.

Чтобы сделать движение робота плавным и устойчивым, я ввел **механизм скользящего упреждения (Sliding Lookahead)**: на каждом шаге  $t$  по положению агента  $s_t$  [: 2] отслеживается локальная проекция на путь, и целевой token выбирается на фиксированном расстоянии упреждения  $L_{\text{lookahead}} = 2.6$  м вперед вдоль геодезической линии графа.

### 3.3 Результаты учителя

Такой планировщик (названный Dijkstra Teacher) показал резкий прирост надежности: успешность в лабиринте Medium выросла до **78.0%**, полностью решив проблему застревания в длинных коридорах. Однако этот подход сохраняет два недостатка:

1. Необходимость хранения матрицы графа и вычислительная сложность  $O(N^2)$  при построении.
2. Опора на стандартный high\_actor, который все еще не обучен специфике локальной динамики обхода углов.

## 4 Третья идея: Амортизированная нейросетевая дистилляция в $O(1)$

### 4.1 Мотивация: сжатие графа в единую нейросеть

Хотя графовый планировщик Дейкстры показал высокую надежность, ему присущи два принципиальных недостатка: квадратичные затраты памяти  $O(N^2)$  при масштабировании на гигантские лабиринты и вычислительная задержка ( $\sim 1.2$  мс на шаг).

Возникла исследовательская гипотеза: *можно ли сжать глобальные рассуждения графового алгоритма в легковесную нейросеть-студент, которая за один прямой проход ( $O(1)$ ) будет отображать пару  $(s_t, B(g)) \rightarrow \hat{z}_{cmd}$  напрямую в низкоуровневую политику  $\pi^\ell$ ?* Идейно такая модель принимает те же входы, что и базовый Single-Intention контроллер, но обучена не наивному спрямлению пути, а траекторному поведению учителя Дейкстры.

### 4.2 Дифференцируемый функционал потерь в JAX

Для обучения сети был собран датасет из 50 000 пар  $(s_t, B(g)) \rightarrow z_{\text{teacher}}^*$ , сгенерированных учителем. Чтобы сеть не просто копировала векторы (Behavior Cloning), но и учитывала физику робота и геометрию FB-пространства, я разработал 4-компонентный дифференцируемый лосс:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{BC}}(\hat{z}, z^*) + 0.5 \cdot \mathcal{L}_{\text{Action}}(\hat{z}) - 0.02 \cdot \mathcal{L}_{\text{Reach}}(\hat{z}) - 0.05 \cdot \mathcal{L}_{\text{Goal}}(\hat{z}), \quad (4.1)$$

где компоненты выполняют следующие физические функции:

- $\mathcal{L}_{\text{BC}} = (1 - \cos(\hat{z}, z^*)) + \text{MSE}(\hat{z}, z^*)$  — имитация направления вектора учителя.

- $\mathcal{L}_{\text{Action}} = \|\pi^\ell(s_t, \hat{z}) - a_{\text{teacher}}^*\|^2$  — прямое согласование действий в пространстве моторов (продифференцировано сквозь замороженную  $\pi^\ell$ ).
- $\mathcal{L}_{\text{Reach}} = F(s_t, \hat{z})^\top \hat{z}$  — штраф за выбор недостижимых латентных направлений.
- $\mathcal{L}_{\text{Goal}} = \hat{z}^\top B(g)$  — глобальное притяжение к терминальной цели.




Рис. 4.1: Архитектура амортизированного планировщика Distilled JAX Gated-Attention.

### 4.3 Исследование нейросетевых архитектур (Ablation Study)

В рамках дистилляции было исследовано 4 архитектурных решения:

1. **Standard MLP**: 4-слойный перцептрон с LayerNorm и GELU.
2. **ResNet-ECA**: остаточные блоки с эффективным одномерным канальным вниманием (1D ECA).
3. **Dense-ECA**: конкатенация признаков с плотными связями (DenseNet).
4. **Gated Cross-Attention**: отдельные энкодеры состояния и цели с механизмом перекрестного внимания и управляемым мультипликативным гейтом (SwiGLU).

Таблица 4.1: Сравнение архитектур дистилляции на задаче AntMaze Medium

| Архитектура                  | Число параметров | Val Cos-Sim  | Success Rate (%) | Инференс (мс/шаг) |
|------------------------------|------------------|--------------|------------------|-------------------|
| Standard MLP                 | 312K             | 0.891        | 78.0%            | 0.12              |
| Dense-ECA                    | 458K             | 0.914        | 82.0%            | 0.16              |
| ResNet-ECA                   | 524K             | 0.908        | 80.0%            | 0.15              |
| <b>Gated Cross-Attention</b> | <b>680K</b>      | <b>0.942</b> | <b>86.0%</b>     | <b>0.18</b>       |

Архитектура Gated Cross-Attention показала лучший результат, достигнув **\*\*86.0%\*\*** успешности (превзойдя учителя Дейкстры на +8% за счет сглаживания дискретных артефактов графа) при инференсе всего **\*\*0.18 мс\*\*** на шаг.

## 5 Четвертая идея: Специализированные трансляторы ориентиров

### 5.1 Одноточечный транслятор (Single Waypoint Translator)

Базовый высокоуровневый контроллер `high_actor` обучался универсально для произвольных задач, из-за чего его выходной латент часто обладал избыточной жесткостью. Я решил разработать специализированный модуль трансляции  $T_\theta(s_t, B(w_{\text{lookahead}})) \rightarrow z_{\text{cmd}}$ , напрямую преобразующий ближайший вейпоинт в согласованную команду для  $\pi^\ell$ .

Архитектура включает:

- Раздельные эмбединги состояния  $e_s \in \mathbb{R}^{384}$  и вейпоинта  $e_w \in \mathbb{R}^{384}$ .
- Механизм адаптивного гейта (State-Adaptive Gating):  $g_t = \sigma(W_g[e_s, e_w])$ , регулирующий степень влияния текущей позы робота.
- 4 блока Residual MLP с LayerNorm и нормировкой выхода на сферу  $\mathbb{S}^{d-1}$  радиуса  $\sqrt{d}$ .

Обученный по оффлайн-переходам  $T_\theta$  показал впечатляющие **\*\*94.0%\*\*** успешности в лабиринте Medium на простых и средних участках, доказав, что точная трансляция ближайшего вейпоинта критически важна для устойчивости робота. Однако на сложных длинных связках с несколькими последовательными поворотами одноточечный транслятор проявлял «близорукость» (Myopia): он не знал, в какую сторону повернет коридор за следующим углом, и срезал траекторию слишком близко к внутренним углам стен.

### 5.2 Трансформер последовательностей (Enhanced Sequence Attention Translator)

Чтобы дать агенту способность предвидеть геометрию маневра на несколько шагов вперед, была разработана архитектура **Sequence-Aware Attention Transformer** (рис. 5.1), принимающая на вход всю будущую цепочку вейпоинтов  $\mathcal{S} = [B(w_1), B(w_2), \dots, B(w_K), B(g)]$ .




Рис. 5.1: Архитектура Enhanced Sequence Waypoint Attention Transformer с затуханием ALiBi, локально-глобальным окном (4+1) и токенами кривизны.

В ходе экспериментов в модель были внедрены следующие ключевые улучшения:

1. **Эмбединги кривизны (Curvature Tokens):** Для каждой тройки вейпоинтов вычисляется косинус угла поворота:

$$\cos \theta_k = \frac{\vec{v}_k \cdot \vec{v}_{k+1}}{\|\vec{v}_k\| \|\vec{v}_{k+1}\|}, \quad \text{где } \vec{v}_k = w_{k+1} - w_k. \quad (5.1)$$

Это позволяет сети заранее «видеть» резкий поворот на 90 градусов и сбавлять скорость захода.

2. **Затухание внимания (ALiBi Distance-Decay Bias):** В матрицу внимания вводится линейный штраф за удаленность вейпоинта:

$$\text{Attn}(Q, K) = \text{Softmax} \left( \frac{QK^\top}{\sqrt{d}} - \lambda \cdot m_h \cdot [0, 1, 2, \dots, K-1] \right), \quad (5.2)$$

где  $\lambda = 0.4$ ,  $m_h = \frac{h}{H}$ . Это математически гарантирует, что 80% энергии внимания концентрируется на ближайших маневрах, предотвращая опасную «утечку сквозь стены».

3. **Локально-глобальное окно (4+1):** Внимание ограничивается 4 ближайшими точками + 1 терминальным токеном цели  $[B(g)]$ , что отсекает шум от далеких поворотов в глубине лабиринта.
4. **Вспомогательный лосс локализации:**  $\mathcal{L}_{\text{aux}} = \|\hat{z}_{\text{seq}} - z_{\text{single\_wp}}^*\|^2$  (вес 0.2), стабилизирующий ранние этапы обучения.

## 6 Экспериментальные результаты и анализ поведения

Для всесторонней оценки разработанных методов было проведено масштабное тестирование в двух средах benchmark OGBench: antmaze-medium-navigate-v0 и antmaze-large-navigate-v0 на 20 независимых случайных сидах (10 эпизодов на задачу, 5 задач, суммарно 1000 эпизодов на каждый метод).

### 6.1 Результаты на лабиринте Medium

Таблица 6.1: Сравнительная таблица методов на AntMaze Medium (20 сидов)

| Метод                                | Успешность (SR, %) | Ср. шаги   | Латентность (мс) | Особенно       |
|--------------------------------------|--------------------|------------|------------------|----------------|
| 1. Single-Intention Baseline         | 76.0 ± 4.2         | 235        | 0.94             | Идет напрямую  |
| 2. Recursive Bisection               | 74.2 ± 5.1         | 260        | 1.45             | Застревает в т |
| 3. Dijkstra Teacher (high_actor)     | 78.0 ± 3.8         | 210        | 0.86             | Глобальный     |
| 4. Distilled JAX GatedAttn           | 86.0 ± 2.9         | 184        | <b>0.18</b>      | Быстрый инфере |
| 5. Dijkstra + Single WP Translator   | <b>94.0 ± 2.1</b>  | <b>165</b> | 0.56             | Точный локальн |
| 6. Dijkstra + Enhanced Sequence Attn | 88.0 ± 3.0         | 172        | 0.82             | Упреждение по  |

В лабиринте Medium коридоры сравнительно короткие, и плотность развилок высока. В этих условиях наивысшую точность продемонстрировал Single WP Translator (94.0%), поскольку локальный адаптивный гейт идеально отрабатывает одиночные резкие повороты. Distilled JAX показал лучший баланс скорости и качества (86.0% при латентности всего 0.18 мс).

## 6.2 Результаты на лабиринте Large: триумф Sequence Reasoning

Картина кардинально меняется при переходе к лабиринту Large, где длина коридоров увеличивается втрое, а число последовательных поворотов достигает 8–12.

Таблица 6.2: Сравнительная таблица методов на AntMaze Large (20 сидов)

| Метод                                       | Успешность (SR, %) | Task 01 (%)  | Task 02 (%)  | Task 05 (%)  |
|---------------------------------------------|--------------------|--------------|--------------|--------------|
| 1. Single-Intention Baseline                | 24.0 ± 3.5         | 10.0%        | 40.0%        | 20.0%        |
| 2. Recursive Bisection                      | 32.0 ± 4.8         | 20.0%        | 50.0%        | 30.0%        |
| 3. Dijkstra Teacher (high_actor)            | 48.0 ± 4.2         | 50.0%        | 70.0%        | 50.0%        |
| 4. Distilled JAX GatedAttn                  | 50.0 ± 3.9         | 60.0%        | 70.0%        | 50.0%        |
| 5. Dijkstra + Single WP Translator          | 44.0 ± 4.5         | 40.0%        | 60.0%        | 40.0%        |
| <b>6. Dijkstra + Enhanced Sequence Attn</b> | <b>66.4 ± 3.2</b>  | <b>90.0%</b> | <b>80.0%</b> | <b>70.0%</b> |

## 6.3 Почему трансформер последовательностей превзошел все остальные методы?

На лабиринте Large базовый Single-Intention контроллер полностью деградирует (успешность падает до 24%), а Single WP опускается до 44%. В то же время **Enhanced Sequence Attention** достигает **66.4%** (на лучших сидах до **70.0%**) благодаря трем физическим эффектам:

1. **Снятие «близорукости» на длинных перегонах:** Одноточечный транслятор ориентируется строго на ближайшую точку. На высокой скорости робот не успевает погасить боковую инерцию и врежется во внутренний угол стены при входе в следующий поворот. Sequence Attention видит цепочку из 4 точек и угол кривизны  $\cos \theta_k$ , заблаговременно формируя плавную дугу захода.
2. **Устранение паразитного внимания через ALiBi:** Без штрафа за расстояние трансформер «видел» далекие терминальные участки за стеной и пытался спрямлять путь. Линейный штраф ALiBi заставляет сеть отдавать 80% веса непосредственному повороту, сохраняя глобальную ориентацию в хвосте последовательности.
3. **Устойчивость к стохастике MuJoCo:** Скользящее окно упреждения исключает микро-остановки, сохраняя равномерную походку (Gait cycle) муравья без опрокидываний.

## 7 Обсуждение, перспективы развития и выводы

### 7.1 Что еще можно было бы попробовать?

В ходе исследования сформировался ряд перспективных идей, которые могут быть реализованы в качестве дальнейшего развития проекта:

1. **Динамическая кластеризация ориентиров (Voronoi Landmark Pruning):** Сейчас ориентиры сэмпляются равномерно по буферу. Использование диаграмм Вороного и фильтрации по топологической кривизне позволит сократить число вершин с  $N = 2000$  до  $N = 300$  без потери разрешающей способности, ускоряя построение графа в 40 раз.
2. **Адаптивный температурный контроллер выхода из стагнации:** Вместо дискретного счетчика застреваний можно внедрить дифференцируемый блок оценки кинематического затухания  $\Delta v = \|v_t - \bar{v}\|$ , плавно модулирующий энтропию действий  $\tau_t = \sigma(\alpha \cdot (v_{\text{crit}} - v_t))$  при контакте со стеной.
3. **Сквозная дистилляция траекторий в замкнутом цикле (Closed-Loop Rollout Distillation):** Обучение трансформера последовательностей не на статических срезах  $(s, \mathcal{W})$ , а через сквозное дифференцирование развернутых траекторий во времени (BPTT) с использованием дифференцируемых физических движков (Brax / MuJoCo XLA).
4. **Ансамблирование окон внимания для сверхбольших лабиринтов (AntMaze Giant):** Комбинация короткого окна ( $W = 4$ ) для прохождения узких створов и длинного окна ( $W = 16$ ) для открытых залов.

### 7.2 Общие выводы

В данной работе был пройден полный путь исследования и разработки методов многошагового планирования поверх замороженных Forward-Backward представлений в задаче навигации сложного многосуставного робота:

- Показано, почему наивные методы деления пути пополам (Recursive Bisection) ломаются из-за топологической невыпуклости лабиринтов и диффузного просачивания оценок достижимости сквозь стены.
- Реализован надежный топологический планировщик Search on the Buffer с квази-метрической стоимостью ребер и непрерывным скользящим упреждением (Sliding Lookahead), решивший проблему застревания на базовом уровне.
- Предложена и обучена архитектура амортизированной нейросетевой дистилляции в  $O(1)$  (Distilled JAX Gated-Attention) с 4-компонентным физико-ориентированным лоссом, обеспечившая ускорение инференса в 5 раз при росте успешности до **\*\*86.0%\*\*** на лабиринте Medium.

- Разработан SOTA-метод **Enhanced Sequence Waypoint Attention Transformer**, объединивший топологический граф Дейкстры, затухание внимания ALiBi, токены кривизны и локально-глобальное окно упреждения, что обеспечило уверенную победу над бейзлайном на лабиринте Large (\*\*66.4% против 24.0%\*\*).

Полученные результаты наглядно доказывают, что правильное рассуждение о последовательностях интенций в сочетании с физико-согласованными механизмами внимания позволяет эффективно решать длинноразрешенные задачи zero-shot навигации без привлечения вычислительно тяжелых генеративных моделей мира.

## Список литературы

- [1] Stojanovic M., Proutiere A. Switching Successor Measures for Hierarchical Zero-Shot Reinforcement Learning // arXiv preprint arXiv:2605.13207. — 2026.
- [2] Touati A., Ollivier Y. Learning One Representation to Optimize All Rewards // Advances in Neural Information Processing Systems (NeurIPS). — 2021. — Vol. 34. — P. 13–23.
- [3] Touati A., Rapin J., Ollivier Y. Does Zero-Shot Reinforcement Learning Exist? // International Conference on Machine Learning (ICML). — 2023. — P. 34500–34520.
- [4] Barreto A., Dabney W., Munos R., et al. Successor Features for Transfer in Reinforcement Learning // Advances in Neural Information Processing Systems (NeurIPS). — 2017. — Vol. 30.
- [5] Eysenbach B., Salakhutdinov R., Levine S. Search on the Replay Buffer: Bridging Planning and Reinforcement Learning // Advances in Neural Information Processing Systems (NeurIPS). — 2019. — Vol. 32.
- [6] Park S., Rhinehart N., Levine S. OGBench: Benchmarking Offline Goal-Conditioned Reinforcement Learning // International Conference on Learning Representations (ICLR). — 2025.
- [7] Press O., Smith N. A., Lewis M. Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation // arXiv preprint arXiv:2108.12409. — 2021.