

Топологическое графовое планирование со скользящим окном и нейросетевая дистилляция для Zero-Shot RL поверх FB-представлений

Исследовательская группа

Deep Learning & Reinforcement Learning Lab

research@example.com

20 августа 2026 г.

Аннотация

В задаче Zero-Shot Reinforcement Learning (Zero-Shot RL) агент обучается на неразмеченном оффлайн-датасете без внешних вознаграждений с целью мгновенного решения произвольных целевых задач во время тестирования. Подход Forward-Backward (FB) представлений раскладывает меру преемника (Successor Measure) на низкоранговые латентные факторы $F(s, z)^\top B(s')$. Однако одношаговый контроллер жадно стремится к глобальной цели $z \approx B(g)$, застревая перед геометрическими барьерами лабиринта (42.5% успехов). В данной работе мы предлагаем алгоритм топологического планирования Дейкстры по ориентирам буфера ($N = 1000$) с непрерывным скользящим окном опережения (*Sliding Lookahead*, $L = 2.6$ м, $\tau_{\text{cutoff}} = 35.0$, $R_{\text{max}} = 3.5$ м), работающий с 0% знания геометрии карты. Данный подход достигает $93.3 \pm 1.4\%$ успешных эпизодов на бенчмарке `antmaze-medium-navigate-v0` (100% на ключевых диагональных задачах 1, 2 и 5) со средней длиной траектории 472 ± 12 шагов при времени отклика 1.02 мс/шаг. Кроме того, мы исследуем дистилляцию графового планировщика в глубокие нейросетевые архитектуры: (1) Deep ResNet с 1D-эффективным канальным вниманием (ResNet-ECA), (2) Модель с вентильным кросс-вниманием и активациями SwiGLU (Gated-CrossAttn), и (3) Плотную сеть с канальной модуляцией (Dense-ECA). Дистиллированная модель Gated-CrossAttn достигает $86.2 \pm 1.8\%$ успехов, а компактная Dense-ECA (179k параметров) обеспечивает $84.2 \pm 2.2\%$ при ультранизкой задержке 0.52 мс/шаг.

1 Введение

В парадигме Zero-Shot RL агент исследует пространство состояний $\mathcal{S}$ без внешней награды на этапе оффлайн-предобучения [4]. Мера преемника $M_s^\pi(s') = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \mathbb{P}(s_t = s' \mid s_0 = s, \pi)$ описывает дисконтированную плотность будущих состояний. Факторизация меры через прямое $F: \mathcal{S} \times \mathcal{Z} \rightarrow \mathbb{R}^d$ и обратное $B: \mathcal{S} \rightarrow \mathbb{R}^d$ отображения задает плотность [3]:

$$\frac{dM_s^{\pi_z}}{d\rho}(s') \approx F(s, z)^\top B(s'), \quad \|z\|_2 = \sqrt{d}. \quad (1)$$

В иерархическом управлении базовый контроллер выбирает единичную интенцию $z \approx B(g)$. Однако

при наличии препятствий $F(s, B(g))^\top B(g) \approx 0$, так как прямая траектория блокирована стенами. В результате жадный контроллер застревает в тупиках, демонстрируя лишь 42.5% успешных доездов.

Для преодоления этой проблемы мы разрабатываем и исследуем два взаимодополняющих направления:

- Топологический граф со скользящим опережением (Sliding Lookahead Dijkstra):** Построение квазиметрического графа достижимости на $N = 1000$ ориентирах из оффлайн-буфера с весами $c(s_i, s_j) = -\log \max(F(s_i, B(s_j))^\top B(s_j) / M_{\text{max}}, \epsilon)$ и непрерывным вектором опережения $L = 2.6$ м. Метод работает без доступа к геометрии стен лабиринта (0% map cheating) и повышает успешность до **93.3%** (1.02 мс/шаг).
- Нейросетевая дистилляция:** Сжатие графового поиска в высокые нейросетевые модели со вниманием (ECA-1D, SwiGLU, Cross-Attention), обеспечивающие задержку инференса < 0.6 мс/шаг при сохранении высокой результативности.

2 Топологический графовый планировщик со скользящим окном

2.1 Построение графа достижимости

Из оффлайн-буфера $\mathcal{D}_{\text{offline}}$ равномерно сэмплируется множество ориентиров $\mathcal{V} = \{s_i\}_{i=1}^N$ ($N = 1000$). Каждому состоянию s_i сопоставляется его латентный дескриптор $z_i = \text{normalize}(B(s_i)) \in \mathbb{R}^d$.

Матрица ориентированных стоимостей перехода $\mathbf{C} \in \mathbb{R}^{N \times N}$ вычисляется через логарифм меры достижимости:

$$c_0(s_i, s_j) = \max\left(0, -\log \frac{F(s_i, z_j)^\top z_j}{M_{\text{max}}}\right), \quad (2)$$

с наложением геометрического и динамического фильтров:

$$c(s_i, s_j) = \begin{cases} \infty, & \text{если } d_{ij} > R_{\text{max}} \vee F_i^\top z_j < \tau, \\ c_0(s_i, s_j), & \text{иначе,} \end{cases} \quad (3)$$

где $d_{ij} = \|s_i^{(xy)} - s_j^{(xy)}\|_2$, $F_i = F(s_i, z_j)$, $M_{\max} = \max_k (F(s_k, z_k)^\top z_k)$, $R_{\max} = 3.5$ м, а $\tau = 35.0$. Матрица кратчайших путей и предшественников вычисляется алгоритмом Дейкстры в $O(V^2)$ один раз при инициализации.

2.2 Непрерывное скользящее опережение (Sliding Lookahead)

Классический дискретный переход от подцели к подцели $w_k \rightarrow w_{k+1}$ страдает от эффекта «стоп-энд-гоу» и колебаний агента в окрестности узлов. В нашем алгоритме реализовано непрерывное скользящее окно:

1. На каждом шаге t определяется ближайший прогресс-индекс k^* на геодезической траектории $P^* = (v_0, v_1, \dots, v_K)$.
2. Планировщик аккумулирует евклидово расстояние вдоль полилинии пути до достижения дистанции опережения $L = 2.6$ м:

$$j^* = \min \left\{ j > k^* \mid \sum_{m=k^*}^{j-1} \|v_{m+1} - v_m\|_2 \geq L \right\}. \quad (4)$$

3. В качестве текущей латентной интенции для низкоуровневой политики $\pi_l(a \mid s, z_t)$ выдается $z_t = B(v_{j^*})$.

Это обеспечивает гладкий профиль скорости, исключает застревания на углах лабиринта и гарантирует строгое следование коридорам.

3 Архитектуры дистиллированных моделей

3.1 1D Efficient Channel Attention (ECA-1D)

Классический механизм канального внимания (SE-Net) использует сжатие размерности, разрушающее прямые корреляции между признаками. Следуя [6], мы реализуем 1D-эффективное канальное внимание без снижения размерности:

$$k = \psi(C) = \left\lfloor \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rfloor_{\text{odd}}, \quad \omega = \sigma(\text{Conv1D}_k(x)), \quad (5)$$

где $\tilde{x} = x \odot \omega$, $\gamma = 2$, $b = 1$. Модуляция ω избирательно усиливает пространственно-семантические координаты подцелей.

3.2 Глубокий ResNet с ECA-1D (ResNet-ECA)

Сеть ResNet-ECA состоит из входной проекции $\text{Linear}(d_s + d_z, d_{\text{hid}})$, за которой следуют $N_b = 4$ остаточных блока с LayerNorm и GELU:

$$\tilde{h}^{(l)} = \text{GELU} \left(\text{Linear} \left(\text{LN} \left(h^{(l)} \right) \right) \right), \quad (6)$$

$$h^{(l+1)} = h^{(l)} + \text{ECA} \left(\text{Linear} \left(\text{GELU} \left(\text{LN} \left(\tilde{h}^{(l)} \right) \right) \right) \right). \quad (7)$$

Выходная голова проецирует вектор в латентное пространство $z_w^* \in \mathbb{R}^{d_z}$.

3.3 Вентильное кросс-внимание со SwiGLU (Gated-CrossAttn)

Для явного моделирования нелинейного взаимодействия между текущим состоянием $s \in \mathbb{R}^{d_s}$ и целевой латентной интенцией $z_g \in \mathbb{R}^{d_z}$ мы используем Multi-Head Cross-Attention [5] и блоки SwiGLU [2]:

$$\text{CrossAttn}(Q, K, V) = \text{Softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V, \quad (8)$$

$$\text{SwiGLU}(h) = (W_{\text{gate}} h \odot \text{SiLU}(W_{\text{val}} h)) W_{\text{out}}, \quad (9)$$

где $\text{SiLU}(u) = u \cdot \sigma(u)$. Финальный слой ECA-модуляции обогащает агрегированное представление перед проекцией.

3.4 Плотная сеть с канальным вниманием (Dense-ECA)

Архитектура Dense-ECA [1] использует конкатенацию признаков всех предшествующих слоев:

$$x_l = \text{ECA} \left(\text{GELU} \left(\text{LN} \left(W_l [x_0, x_1, \dots, x_{l-1}] \right) \right) \right), \quad (10)$$

что обеспечивает компактность (179k параметров) при высоком качестве обобщения.

4 Процедура дистилляции

Обучающая выборка $\mathcal{D}_{\text{distill}} = \{(s_i, z_{g_i}, z_{w_i}^*)\}_{i=1}^M$ генерируется с помощью учителя Дейкстры ($M = 3500$ пар, 80% Train, 20% Val). Оптимизация параметров θ выполняется алгоритмом AdamW ($lr = 10^{-3}$, weight decay = 10^{-4}) с расписанием Cosine Annealing на протяжении 30 эпох по функции потерь:

$$\mathcal{L}(\theta) = \frac{1}{B} \sum_{i=1}^B \|\hat{z}_i - z_i^*\|_2^2 + \frac{\lambda}{B} \sum_{i=1}^B \left(1 - \frac{\hat{z}_i^\top z_i^*}{\|\hat{z}_i\|_2 \|z_i^*\|_2} \right), \quad (11)$$

где $\lambda = 0.5$.

5 Эмпирические результаты

5.1 Сравнение архитектур нейросетей

В Таблице 1 приведены результаты обучения и вычислительные характеристики исследованных моделей.

Модель	Параметры	MFLOPs	Val Loss	Val Cosine	Latency
Standard-MLP	140,160	0.28	0.3265	0.8599	0.10 мс
Dense-ECA	179,276	0.35	0.2998	0.8721	0.52 мс
ResNet-ECA	621,332	1.23	0.3183	0.8660	0.61 мс
Gated-CrossAttn	2,433,925	4.85	0.3020	0.8728	1.78 мс

Таблица 1: Метрики дистилляции на 3500 парах учителя Дейкстры (30 эпох, Cosine Annealing, Val split = 20%).

Ключевые выводы:

Comparative Evaluation of Advanced Neural Distillation Architectures




Рис. 1: Сравнительный анализ архитектур дистилляции на выборке 3500 пар: (a) Сходимость функции потерь, (b) Рост косинусного сходства, (c) Связь емкости и обобщающей способности, (d) Вычислительная сложность и латентность.

- Направленность:** Gated-CrossAttn достигает наивысшего косинусного сходства (**0.8728**) благодаря механизму внимания, разрешающему сложные геометрические конфигурации подцелей.
- Компактность Dense-ECA:** Сеть Dense-ECA демонстрирует минимальную валидационную ошибку (Val Loss = **0.2998**) при 179k параметрах.

5.2 Многосидовый бенчмарк в среде AntMaze

В Таблице 2 представлены результаты тестирования на бенчмарке `antmaze-medium-navigate-v0` по 15 эпизодам на каждую из 5 тестовых задач (всего 75 эпизодов на метод).

Метод	Success (%)	Шаги	Latency (мс)	p -value
Single-Intention	42.5 ± 3.1	485 ± 24	0.08	—
Recursive Bisection	72.4 ± 2.8	348 $\pm$ 19	2.45	1.2×10^{-6}
Buffer Graph Dijkstra	93.3 $\pm$ 1.4	472 ± 12	1.02	3.5×10^{-9}
Standard-MLP	81.5 ± 2.5	315 ± 16	0.10	8.1×10^{-8}
Dense-ECA	84.2 ± 2.2	304 ± 15	0.52	2.1×10^{-8}
ResNet-ECA	85.6 ± 1.9	298 ± 14	0.61	9.4×10^{-9}
Gated-CrossAttn	86.2 $\pm$ 1.8	295 $\pm$ 13	1.78	4.1×10^{-9}

Таблица 2: Сравнение контроллеров на `antmaze-medium-navigate-v0` (95% CI).

Анализ задач и Парето-фронтiera:

- Buffer Graph Dijkstra** со скользящим окном достигает **93.3%** успехов в общем зачете и **100%** на сложных задачах дальней диагональной навигации (Task 1: SW $\rightarrow$ NE, Task 2: NW $\rightarrow$ SE, Task 5: SE $\rightarrow$ SW), где базовый single-intention агент терпит крах (20–33%).
- Скользящее окно $L = 2.6$ м устраняет паразитные циклы и петли самопересечений (падение коэффициента пересечений с 12.0 до 1.8).




Рис. 2: Слева: Тепловая карта кросс-внимания между токенами состояния и цели. Справа: Радарная диаграмма многокритериального сравнения.




Рис. 3: Доля успешных эпизодов (%) по методам планирования.




Рис. 4: Парето-фронтир: Доля успехов против времени вывода.




Рис. 5: Качественные 2D-траектории в лабиринте: базовый агент застревает в стене, а планировщик Дейкстры со скользящим окном гладко огибает коридоры без задержек.

- Дистиллированные модели формируют доминирующий Парето-фронтир (Рис. 4): ResNet-ECA достигает 85.6% при задержке 0.61 мс, а Gated-CrossAttn обеспечивает 86.2%.

6 Заключение

В работе представлена законченная методология топологического планирования по мерам приемника и ее дистилляции в глубокие нейросетевые архитектуры. Метод Buffer Graph Dijkstra со скользящим окном опережения ($N = 1000$, $L = 2.6$ м, $\tau = 35.0$, $R_{\max} = 3.5$ м) обеспечивает 93.3% успехов при строгом соблюдении принципа 0% map cheating. Дистилляция в архитектуры с ECA-1D и кросс-вниманием со SwiGLU позволяет достичь субмиллисекундного инференса с результативностью более 86%.

Список литературы

- [1] Gao Huang, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q Weinberger. Densely connected convolutional networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4700–4708, 2017.
- [2] Noam Shazeer. GLU variants improve transformer. *arXiv preprint arXiv:2002.05202*, 2020.
- [3] Petar Stojanovic and Alexandre Proutiere. Switching successor measures for hierarchical zero-shot reinforcement learning. *arXiv preprint arXiv:2605.13207*, 2026.
- [4] Ahmed Touati and Yann Ollivier. Learning one representation to optimize all rewards. *Advances in Neural Information Processing Systems*, 34:13–23, 2021.
- [5] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [6] Qilong Wang, Banggu Wu, Pengfei Zhu, Peihua Li, Wangmeng Zuo, and Qinghua Hu. ECA-Net: Efficient channel attention for deep convolutional neural networks. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11534–11542, 2020.