

Дистилляция топологического графового планирования в высокопроизводительные нейросетевые архитектуры для Zero-Shot обучения с подкреплением

Исследовательская группа

Deep Learning & Reinforcement Learning Lab

research@example.com

18 августа 2026 г.

Аннотация

В задаче Zero-Shot Reinforcement Learning (Zero-Shot RL) агент обучается на неразмеченном оффлайн-датасете без вознаграждений с целью мгновенного решения произвольных целевых задач во время тестирования. Подход Forward-Backward (FB) представленный раскладывает меру преемника (Successor Measure) на низкоранговые латентные факторы $F(s, z)^\top B(s')$. Однако одношаговый контроллер жадно стремится к глобальной цели $z \approx B(g)$, застревая перед непреодолимыми геометрическими барьерами лабиринта. Топологический поиск кратчайших путей Дейкстры на ориентирах буфера гарантирует нахождение глобально оптимальных цепочек подцелей, но создает задержку $O(V^2)$ (≈ 7.82 мс/шаг). В данной работе мы решаем задачу дистилляции учителя Дейкстры в передовые нейросетевые архитектуры: (1) Deep ResNet с 1D-эффективным канальным вниманием (ResNet-ECA), (2) Модель с вентильным кросс-вниманием между состоянием и целью с активациями SwiGLU (Gated-CrossAttn), и (3) Плотную рекуррентную сеть с канальной модуляцией (Dense-ECA). На выборке из 3500 пар оптимальных переходов с расписанием Cosine Annealing модель Gated-CrossAttn достигает косинусного сходства 0.8728, а в онлайн-роллаутах на `antmaze-medium-navigate-v0` по 10 независимым сессам показывает $86.2 \pm 1.8\%$ успехов (сопоставимо с учителем 86.8%) при ускорении принятия решений в $4.4\times$ (1.78 мс против 7.82 мс). Компактная модель Dense-ECA (179к параметров) обеспечивает $84.2 \pm 2.2\%$ при ультранизкой задержке 0.52 мс/шаг.

1 Введение

В парадигме Zero-Shot RL агент исследует пространство состояний $\mathcal{S}$ без внешней награды на этапе оффлайн-предобучения [4]. Мера преемника $M_s^\pi(s') = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \mathbb{P}(s_t = s' \mid s_0 = s, \pi)$ описывает дисконтированную плотность будущих состояний. Факторизация меры через прямое $F : \mathcal{S} \times \mathcal{Z} \rightarrow \mathbb{R}^d$ и обратное $B : \mathcal{S} \rightarrow \mathbb{R}^d$ отображения задает плотность [3]:

$$\frac{dM_s^{\pi_z}}{d\rho}(s') \approx F(s, z)^\top B(s'), \quad \|z\|_2 = \sqrt{d}. \quad (1)$$

В иерархическом управлении базовый контроллер выбирает $z \approx B(g)$. Однако при наличии стен

$F(s, B(g))^\top B(g) \approx 0$, так как прямая траектория заблокирована. Построение топологического графа на $N = 200$ ориентирах буфера с весами $c(s_i, s_j) = -\log \max(F(s_i, B(s_j))^\top B(s_j), \epsilon)$ позволяет алгоритму Дейкстры находить оптимальные подцели $s \rightarrow w_1^* \rightarrow \dots \rightarrow g$, поднимая долю успехов с 42.5% до 86.8%, но увеличивая задержку инференса до 7.82 мс/шаг.

Цель настоящей работы — разработка и строгое математическое исследование высокочисленных и вычислительно эффективных нейросетевых архитектур для дистилляции оптимального оператора Дейкстры $\pi_\theta^h(s, B(g)) \approx B(w_1^*)$.

2 Архитектуры дистиллированных моделей

2.1 1D Efficient Channel Attention (ECA-1D)

Классический механизм канального внимания (SE-Net) использует редукцию размерности через «бутылочное горлышко», что разрушает прямые корреляции между каналами. Следуя [6], мы реализуем 1D-эффективное канальное внимание без снижения размерности.

Для скрытого вектора признаков $x \in \mathbb{R}^{B \times C}$ адаптивный размер ядра одномерной свертки k определяется нелинейной функцией от числа каналов C :

$$k = \psi(C) = \left\lfloor \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rfloor_{\text{odd}}, \quad (2)$$

где $\lfloor \cdot \rfloor_{\text{odd}}$ обозначает ближайшее нечетное целое число (≥ 3), $\gamma = 2$, $b = 1$. Модуляция каналов $\omega \in \mathbb{R}^C$ вычисляется как:

$$\omega = \sigma(\text{Conv1D}_k(x)), \quad \tilde{x} = x \odot \omega, \quad (3)$$

где Conv1D_k — одномерная свертка по канальной оси с паддингом $(k-1)/2$, сохраняющая длину C , а σ — сигмоида. Вектор ω избирательно усиливает пространственно-семантические координаты подцелей.

2.2 Глубокий ResNet с ECA-1D (ResNet-ECA)

Сеть ResNet-ECA состоит из входной проекции $\text{Linear}(d_s + d_z, d_{\text{hid}})$, за которой следуют $N_b = 4$ остаточных блока с LayerNorm и GELU:

$$\tilde{h}^{(l)} = \text{GELU}\left(\text{Linear}\left(\text{LN}\left(h^{(l)}\right)\right)\right), \quad (4)$$

$$h^{(l+1)} = h^{(l)} + \text{ECA}\left(\text{Linear}\left(\text{GELU}\left(\text{LN}\left(\tilde{h}^{(l)}\right)\right)\right)\right). \quad (5)$$

Выходная голова проецирует латентное состояние в целевой вектор $z_{w_1}^* \in \mathbb{R}^{d_z}$.

2.3 Вентильное кросс-внимание со SwiGLU (Gated-CrossAttn)

Для явного моделирования нелинейного взаимодействия между текущим физическим состоянием агента $s \in \mathbb{R}^{d_s}$ и целевой латентной интенцией $z_g \in \mathbb{R}^{d_z}$, мы разрабатываем архитектуру на базе Multi-Head Cross-Attention [5] и вентильных блоков SwiGLU [2].

Состояние s токенизируется в матрицу запросов $Q \in \mathbb{R}^{B \times N_q \times d_{\text{model}}}$, а целевая интенция z_g — в матрицу ключей и значений $K, V \in \mathbb{R}^{B \times N_k \times d_{\text{model}}}$. Кросс-внимание для H голов вычисляется как:

$$\text{CrossAttn}(Q, K, V) = \text{Softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V, \quad (6)$$

где $d_k = d_{\text{model}}/H$. Блок нелинейной трансформации SwiGLU реализует управляемую фильтрацию признаков:

$$\text{SwiGLU}(h) = (W_{\text{gate}}h \odot \text{SiLU}(W_{\text{val}}h))W_{\text{out}}, \quad (7)$$

где $\text{SiLU}(u) = u \cdot \sigma(u)$. Финальный слой ECA-модуляции обогащает агрегированное представление перед проекцией в латентное пространство.

2.4 Плотная сеть с канальным вниманием (Dense-ECA)

Архитектура Dense-ECA [1] использует конкатенацию признаков всех предшествующих слоев:

$$x_l = \text{ECA}\left(\text{GELU}\left(\text{LN}\left(W_l[x_0, x_1, \dots, x_{l-1}]\right)\right)\right), \quad (8)$$

где $x_l \in \mathbb{R}^{d_{\text{growth}}}$, $d_{\text{growth}} = 64$. Это обеспечивает многоуровневое переиспользование признаков при компактном размере модели (179k параметров).

3 Процедура обучения и дистилляции

Обучающая выборка $\mathcal{D}_{\text{distill}} = \{(s_i, z_{g_i}, z_{w_1^*}^i)\}_{i=1}^M$ генерируется с помощью учителя Дейкстры на $N = 200$ ориентирах ($M = 3500$ пар). Выборка разделяется на Train Split (80%, 2800 пар) и Validation Split (20%, 700 пар).

Оптимизация параметров θ выполняется алгоритмом AdamW ($lr = 10^{-3}$, weight decay = 10^{-4}) с расписанием Cosine Annealing на протяжении 30 эпох по композитной функции потерь:

$$\mathcal{L}(\theta) = \frac{1}{B} \sum_{i=1}^B \|\hat{z}_i - z_i^*\|_2^2 + \frac{\lambda}{B} \sum_{i=1}^B \left(1 - \frac{\hat{z}_i^\top z_i^*}{\|\hat{z}_i\|_2 \|z_i^*\|_2}\right), \quad (9)$$

где $\lambda = 0.5$.

4 Эмпирические результаты

4.1 Сравнение архитектур нейросетей

В Таблице 1 приведены результаты обучения и вычислительные характеристики 4 исследованных моделей.

Таблица 1: Метрики дистилляции на 3500 парах Дейкстры (30 эпох, Cosine Annealing, Val split = 20%).

Модель	Параметры	MFLOPs	Val Loss	Val Cosine I
Standard-MLP	140, 160	0.28	0.3265	0.8599
Dense-ECA	179, 276	0.35	0.2998	0.8721
ResNet-ECA	621, 332	1.23	0.3183	0.8660
Gated-CrossAttn	2, 433, 925	4.85	0.3020	0.8728

Ключевые выводы:

- 1. Качество направленности:** Gated-CrossAttn достигает наивысшего косинусного сходства (**0.8728**) и минимальной ошибки на обучении ($\mathcal{L}_{\text{train}} = 0.0455$), что подтверждает способность кросс-внимания разрешать неоднозначности между положением агента и сложными конфигурациями целей.
- 2. Эффективность Dense-ECA:** Сеть Dense-ECA демонстрирует наилучшую регуляризацию (Val Loss = **0.2998**, Val MSE = **0.2358**) при всего 179k параметров благодаря повторному использованию карт признаков и 1D канальному вниманию.

4.2 Многосидовый бенчмарк в среде AntMaze

В Таблице 2 представлены результаты 10-сидового онлайн-тестирования на бенчмарке `antmaze-medium-navigate-v0` (150 эпизодов на метод).

Как видно из Рисунка 4, дистиллированные модели формируют доминирующий Парето-фронт: ResNet-ECA достигает 85.6% успехов при задержке всего 0.61 мс (12.8× быстрее учителя Дейкстры), а Gated-CrossAttn практически полностью воспроизводит производительность графового поиска (86.2% против 86.8%).

5 Заключение

В работе представлена методология дистилляции топологического графового планирования в современ-

Comparative Evaluation of Advanced Neural Distillation Architectures




Рис. 1: Сравнительный анализ архитектур дистилляции на выборке 3500 пар: (a) Сходимость функции потерь, (b) Рост косинусного сходства, (c) Связь емкости и обобщающей способности, (d) Вычислительная сложность и латентность.




Рис. 2: Слева: Тепловая карта кросс-внимания между токенами состояния и цели. Справа: Радарная диаграмма многокритериального сравнения.

ные нейросетевые архитектуры. Интеграция 1D эффективного канального внимания (ECA-1D) и вентильного кросс-внимания со SwiGLU позволяет преодолеть проблему длинного горизонта в Zero-Shot RL с высокой точностью и миллисекундным временем отклика.

Список литературы

[1] Gao Huang, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q Weinberger. Densely connected convolutional networks. In *IEEE Conference on*

Таблица 2: Сравнение контроллеров на `antmaze-medium-navigate-v0` (10 сидов, 150 эпизодов/метод, 95% CI).

Метод	Success (%)	Шаги	Latency (мс)	p -value
Single-Intention	42.5 ± 3.1	485 ± 24	0.08	—
Branch 1: Bisection	72.4 ± 2.8	348 ± 19	2.45	1.2×10^{-5}
Branch 2: Dijkstra	86.8 ± 2.1	292 ± 14	7.82	3.5×10^{-6}
Standard-MLP	81.5 ± 2.5	315 ± 16	0.10	8.1×10^{-5}
Dense-ECA	84.2 ± 2.2	304 ± 15	0.52	2.1×10^{-4}
ResNet-ECA	85.6 ± 1.9	298 ± 14	0.61	9.4×10^{-5}
Gated-CrossAttn	86.2 ± 1.8	295 ± 13	1.78	4.1×10^{-6}

Computer Vision and Pattern Recognition (CVPR), pages 4700–4708, 2017.

[2] Noam Shazeer. GLU variants improve transformer. *arXiv preprint arXiv:2002.05202*, 2020.

[3] Petar Stojanovic and Alexandre Proutiere. Switching successor measures for hierarchical zero-shot reinforcement learning. *arXiv preprint arXiv:2605.13207*, 2026.

[4] Ahmed Touati and Yann Ollivier. Learning one representation to optimize all rewards. *Advances in Neural Information Processing Systems*, 34:13–23, 2021.




Рис. 3: Доля успешных эпизодов (%) по 10 независимым седам.




Рис. 4: Парето-фронт: Доля успехов против времени вывода.

- [5] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [6] Qilong Wang, Banggu Wu, Pengfei Zhu, Peihua Li, Wangmeng Zuo, and Qinghua Hu. ECA-Net: Efficient channel attention for deep convolutional neural networks. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11534–11542, 2020.




Рис. 5: Качественные 2D-траектории в лабиринте: базовый агент застревает в стене, а дистиллированный контроллер ResNet-ECA / Gated-CrossAttn гладко обходит коридоры.