

Мульти-субгольное планирование на основе ФВ-представлений для zero-shot обучения с подкреплением

Исследовательская группа

Deep Learning & Reinforcement Learning Lab

research@example.com

17 августа 2026 г.

Аннотация

В Zero-Shot Reinforcement Learning (Zero-Shot RL) агент обучается на неразмеченном оффлайн-датасете с целью решения произвольных задач во время тестирования без дополнительного взаимодействия со средой. Подход Forward-Backward (FB) представлений раскладывает меру преемника (Successor Measure) на низкоранговые эмбединги. Однако базовый иерархический контроллер выбирает лишь одну латентную интенцию $z \sim \pi_h(z|s, g)$ за раз, что приводит к застреванию агента в сложных лабиринтах на длинных горизонтах. В данной работе предложены и исследованы три механизма планирования цепочек подцелей в латентном пространстве FB без применения генеративных моделей мира: (1) Рекурсивное деление траектории (Divide & Conquer), (2) Топологический поиск кратчайших путей на Replay Buffer (Dijkstra), и (3) Дистилляция графа в ультра-легковесную нейросеть π_θ^h . Эксперименты на бенчмарке OGBench (antmaze-medium-navigate-v0) показывают рост доли успехов с 42.5% до 86.8% при сохранении миллисекундной задержки инференса.

1 Введение

В задаче zero-shot RL агент получает функцию награды $r(s, a)$ лишь во время тестирования [3]. Мера преемника $M_s^\pi(s') = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \mathbb{P}(s_t = s' | s_0 = s, \pi)$ описывает дисконтированную плотность будущих посещений состояний. ФВ-представления аппроксимируют производную Радона-Никодима через скалярное произведение [2]:

$$\frac{dM_s^{\pi_z}}{d\rho}(s') \approx F(s, z)^\top B(s'), \quad (1)$$

где $F(s, z)$ — forward-эмбединг будущего поведения под действием латентной интенции z ($\|z\|_2 = \sqrt{d}$), а $B(s')$ — backward-эмбединг целевого состояния.

В иерархической схеме одноинтенциональный бейзлайн жадно выбирает $z \approx B(g)$. Однако в лабиринтах с препятствиями и тупиками $F(s, B(g))^\top B(g) \approx 0$, так как прямая траектория физически заблокирована стенами, что приводит к застреванию агента.

2 Методология мульти-субгольного планирования

Для преодоления барьера длинного горизонта мы строим цепочку промежуточных подцелей $(w_1^*, w_2^*, \dots, w_K^*, g)$ с использованием только замороженных сетей F, B и оффлайн-буфера $\mathcal{D}$.

2.1 Квази-метрическое расстояние в ФВ-пространстве

Эффективное направленное расстояние от состояния s_i до подцели s_j определяется как отрицательный логарифм меры достижимости:

$$c(s_i, s_j) = -\log \left(\max \left(\frac{F(s_i, B(s_j))^\top B(s_j)}{\|F\|_2 \|B\|_2}, \epsilon \right) \right). \quad (2)$$

2.2 Ветка 1: Рекурсивное деление (Divide & Conquer)

Для пары (s, g) оптимальная медианная точка w^* максимизирует совместную плотность переходов:

$$w^* = \arg \max_{w \in \mathcal{V}} [\log(F(s, B(w))^\top B(w)) + \log(F(w, B(g))^\top B(g))]. \quad (3)$$

Если $F(s, B(w^*))^\top B(w^*) < \tau_{\text{reach}}$, подотрезок $[s, w^*]$ рекурсивно делится дальше до глубины $D_{\text{max}} = 3$.

2.3 Ветка 2: Топологический граф на Replay Buffer

Мы отбираем $N = 150$ ориентиров $V \subset \mathcal{D}$ с помощью Farthest Point Sampling (FPS). Построив матрицу смежности $C_{ij} = c(s_i, s_j)$, алгоритм Дейкстры находит глобально кратчайший путь в обход стен $s \rightarrow w_1^* \rightarrow \dots \rightarrow g$. Контроллер динамически переключает интенцию $z_k = B(w_k^*)$ при входе в окрестность $\|s - w_k^*\|_2 < \delta_{\text{switch}}$.

2.4 Ветка 3: Дистиллированный контроллер π_θ^h

Чтобы исключить вычислительную сложность графового поиска во время выполнения ($O(V^2)$), мы




Рис. 1: Сравнение доли успешных эпизодов на бенчмарке OGBench.




Рис. 2: Парето-фронт: доля успехов в зависимости от времени принятия решения на шаг (логарифмическая шкала).

дистиллируем кратчайшие пути в 3-слойную MLP $\pi_{\theta}^h(s, B(g)) \rightarrow z_{w_1^*}$:

$$\mathcal{L}(\theta) = \mathbb{E} [\|\pi_{\theta}^h(s, B(g)) - B(w_1^*)\|_2^2 + \lambda(1 - \cos(\hat{z}, z^*))]. \quad (4)$$

Инференс выполняется за $O(1)$ время (< 0.3 мс/шаг) без тяжелых моделей мира.

3 Экспериментальные результаты

Оценка проведена на среде `ogbench-antmaze-medium-navigate-v0` [1] по 5 независимым седам (0, 1, 2, 3, 4).

Таблица 1: Сравнение методов планирования на `antmaze-medium-navigate-v0` (5 сидов).

Метод	Success (%)	Шаги	Latency (мс)
Single-Intention Baseline	42.5 ± 3.1	485 ± 24	0.08
Branch 1: Bisection	72.4 ± 2.8	348 ± 19	2.45
Branch 2: Buffer Graph	86.8 ± 2.1	292 ± 14	7.82
Branch 3: Distilled MLP	81.5 ± 2.5	315 ± 16	0.28




Рис. 3: 2D-траектории навигации агента: базовый контроллер застревает в тупике, в то время как граф и дистиллированная MLP успешно обходят лабиринт.

4 Обсуждение и Анализ

Как видно из Таблицы 1 и Рисунка 2, все три предложенных метода статистически значительно превосходят бейзлайн ($p < 10^{-4}$). Графовый поиск (Ветка 2) обеспечивает наивысшую надежность (86.8%), однако требует вычисления матрицы расстояний. Дистилляция (Ветка 3) достигает 81.5% успеха при задержке всего 0.28 мс/шаг, решая задачу реального времени.

5 Заключение

Мульти-субгольное планирование непосредственно над FB-представлениями устраняет проблему длинного горизонта в Zero-Shot RL без необходимости обучения тяжелых генеративных моделей мира, удовлетворяя всем академическим и вычислительным ограничениям.

Список литературы

- [1] Seohong Park et al. Ogbench: Benchmarking offline goal-conditioned rl. *arXiv preprint arXiv:2410.20092*, 2025.
- [2] Petar Stojanovic and Alexandre Proutiere. Switching successor measures for hierarchical zero-shot reinforcement learning. *arXiv preprint arXiv:2605.13207*, 2026.

[3] Ahmed Touati and Yann Ollivier. Learning one representation to optimize all rewards. *Advances in Neural Information Processing Systems*, 34:13–23, 2021.