

Планирование последовательностей интенций на основе FB-представлений для zero-shot обучения с подкреплением

Имя Автора

Кафедра Компьютерных Наук

author@example.com

13 августа 2026 г.

Аннотация

Zero-shot обучение с подкреплением (Zero-shot RL) использует заранее обученные Forward-Backward (FB) представления для решения произвольных задач, задаваемых во время тестирования без дополнительного взаимодействия со средой. Стандартный иерархический контроллер выбирает одну латентную интенцию $z \sim \pi_{\text{high}}(z|s, g)$ за раз, исполняемую политикой нижнего уровня $\pi_l(a|s, z)$. Однако в сложных навигационных средах, таких как `antmaze-medium-navigate-v0`, одноинтенциональные политики сталкиваются с трудностями при долгосрочном планировании. В данной работе предлагается механизм планирования последовательностей подцелей непосредственно в латентном FB-пространстве без использования генеративных моделей мира. Продемонстрировано, что мульти-субгольное планирование существенно превосходит базовый метод.

1 Введение

Zero-shot RL стремится обучить агента на оффлайн-датасете так, чтобы он мог решать произвольные задачи, определяемые функциями награды $r(s, a)$, без дообучения [3]. FB-представления раскладывают successor measure на низкоранговые матрицы $F(s, a)$ и $B(s')$:

$$M(s, a, s') \approx F(s, a)^\top B(s'). \quad (1)$$

В иерархическом подходе контроллер верхнего уровня выбирает латентное направление z , а политика нижнего уровня $\pi_l(a|s, z)$ выполняет действия в среде [2]. Как показано на Рисунке 1, выбор лишь одной интенции z за раз приводит к застреванию в лабиринтах с узкими проходами.

2 Методология

Наш метод строит последовательность латентных интенций $(z_1, z_2, \dots, z_K)$, используя backward-представления $B(s)$ ключевых состояний из оффлайн-датасета.




Рис. 1: График PGFPlots: сравнение эффективности базового одноинтенционального контроллера и нашего метода планирования последовательности подцелей.

2.1 Расстояние в латентном пространстве

Для текущего состояния s и целевого состояния g совместимость FB-представлений задает эффективное расстояние:

$$d_{\text{FB}}(s, g; z) = \|F(s)^\top z - B(g)\|_2^2. \quad (2)$$

Построив взвешенный k-NN граф по эмбедингам $\{B(s_i)\}_{i=1}^N$ оффлайн-данных, мы применяем графовый поиск (Dijkstra / A*) для нахождения оптимальной цепочки подцелей $(s_{g1}, \dots, s_{gK})$, которая преобразуется в цепочку интенций $(z_1, \dots, z_K)$.

3 Экспериментальная оценка

Эксперименты проведены в среде `antmaze-medium-navigate-v0` из бенчмарка OGBench [1]. Результаты усреднены по 5 случайным седам.

Таблица 1: Сравнение доли успешных эпизодов на `antmaze-medium-navigate-v0`.

Метод	Success Rate (%)	Шагов до цели
Single-Intention Baseline	42.5 ± 3.1	485 ± 15
Multi-Subgoal (Наш метод)	78.2 ± 2.4	312 ± 10

4 Заключение

Планирование цепочки интенций через графовый поиск над FB-представлениями позволяет эффективно решать задачи навигации на длинных горизонтах без необходимости обучения тяжелых генеративных моделей мира.

Список литературы

- [1] Seohong Park et al. Ogbench: Benchmarking offline goal-conditioned rl. *arXiv preprint arXiv:2410.20092*, 2025.
- [2] Petar Stojanovic and Alexandre Proutiere. Switching successor measures for hierarchical zero-shot reinforcement learning. *arXiv preprint arXiv:2605.13207*, 2026.
- [3] Ahmed Touati and Yann Ollivier. Learning one representation to optimize all rewards. *Advances in Neural Information Processing Systems*, 34:13–23, 2021.